Large Language Model: L'Addestramento — Dataset, Pre-training e Fine-tuning

Come un modello linguistico apprende a comprendere e generare il linguaggio

---

1. I dati di addestramento: il dataset di un LLM

1.1 Da dove provengono i testi usati per l'addestramento

Il dataset di addestramento di un Large Language Model è costituito da un volume di testo che comprende, in larga misura, porzioni significative di tutto il materiale scritto disponibile pubblicamente online: pagine web di ogni genere, articoli di enciclopedie collaborative, forum di discussione, archivi di libri non più coperti da diritti d'autore o concessi in licenza, articoli scientifici, codice sorgente di programmi informatici e, in alcuni casi, materiali concessi in licenza specificamente per questo scopo da editori o altre organizzazioni titolari dei contenuti.

La raccolta di questi testi avviene attraverso processi automatizzati di scansione ed estrazione di contenuti dal web, integrati da collezioni di dati già strutturate e rese disponibili dalla comunità di ricerca, un lavoro preliminare che precede di gran lunga, in termini di complessità organizzativa, la fase di addestramento vera e propria del modello, e

che determina in misura sostanziale la qualità finale del sistema che ne deriva.

Una parte del dataset è inoltre costituita da conversazioni e testi generati appositamente per l'addestramento, spesso prodotti o rivisti da persone incaricate a questo scopo, un contributo che diventa via via più rilevante nelle fasi successive di perfezionamento del modello, descritte nella sezione dedicata al fine-tuning, rispetto alla fase iniziale di pre-training in cui prevale nettamente il testo raccolto dal web.

1.2 Qualità e pulizia dei dati: perché non basta "tanto testo"

Non tutto il testo disponibile online è ugualmente utile ai fini dell'addestramento di un modello linguistico: contenuti duplicati, testi di scarsa qualità editoriale, pagine generate automaticamente con finalità puramente pubblicitarie o contenuti privi di una struttura linguistica coerente, se inclusi senza alcun filtro, rischiano di peggiorare, anziché migliorare, la qualità complessiva del modello risultante, insegnandogli regolarità linguistiche poco rappresentative del modo in cui le persone comunicano effettivamente.

Per questo motivo, prima di essere utilizzato per l'addestramento, il materiale raccolto viene sottoposto a un processo di pulizia e selezione

piuttosto articolato, che comprende l'eliminazione di duplicati, il filtraggio di contenuti di bassa qualità o palesemente generati in modo automatico, la rimozione di informazioni personali identificabili laddove tecnicamente possibile, e una serie di controlli volti a escludere, per quanto possibile, contenuti illegali o manifestamente dannosi dal materiale che il modello arriverà a osservare.

Questo lavoro di preparazione dei dati rappresenta oggi una componente tanto rilevante quanto la scala stessa del modello nel determinarne la qualità finale, al punto che, a parità di dimensione, due modelli addestrati su dataset preparati con un diverso livello di cura possono raggiungere risultati sensibilmente diversi, un aspetto che spiega perché le organizzazioni che sviluppano questi sistemi investano risorse crescenti proprio nella fase di raccolta e selezione dei dati, oltre che nell'addestramento vero e proprio.

Accanto alla pulizia tecnica del materiale, un ulteriore accorgimento riguarda la ponderazione delle diverse fonti incluse nel dataset: non tutte le tipologie di testo vengono trattate allo stesso modo nella composizione finale della raccolta di addestramento, e fonti considerate più affidabili o meglio scritte, come articoli enciclopedici curati o

pubblicazioni specialistiche, ricevono spesso un peso maggiore rispetto a contenuti generici raccolti dal web, un accorgimento che contribuisce a orientare il modello verso uno stile e un livello di accuratezza mediamente più elevati.

1.3 Bias e rappresentatività: i limiti che vengono dai dati

Poiché un Large Language Model apprende esclusivamente da ciò che è contenuto nel proprio dataset, ogni squilibrio, distorsione o lacuna presente in quei dati tende a riflettersi, in qualche misura, nel comportamento del modello risultante: una sovrarappresentazione di certi punti di vista, di certe lingue o di certi contesti culturali rispetto ad altri produce, inevitabilmente, un modello più accurato e a proprio agio su quei temi rispetto ad altri meno rappresentati nel materiale di addestramento.

Questo fenomeno, generalmente indicato con il termine bias, non è la conseguenza di una scelta intenzionale, ma un effetto pressoché inevitabile del fatto che il testo disponibile online non costituisce, di per sé, un campione perfettamente equilibrato e rappresentativo di tutte le lingue, culture, opinioni e prospettive esistenti nel mondo, per quanto le organizzazioni che sviluppano questi modelli adottino accorgimenti specifici volti a mitigarne, almeno in parte, gli effetti più evidenti.

Per chi utilizza questi strumenti nella propria attività, la consapevolezza di questo aspetto si traduce in un'attenzione pratica molto concreta: un modello può risultare meno accurato o meno equilibrato su argomenti di nicchia, lingue meno diffuse o contesti locali specifici rispetto a temi più generali e ampiamente rappresentati online, un motivo in più per sottoporre sempre a verifica le risposte ottenute su questioni particolarmente specifiche o sensibili.

In pratica

- Il dataset di un LLM proviene in larga parte da testo raccolto pubblicamente dal web
- La qualità e la pulizia dei dati incidono sul risultato quanto, se non più, della sola quantità
- Squilibri nei dati di addestramento producono inevitabilmente bias nel comportamento del modello
- Argomenti di nicchia o lingue meno diffuse possono risultare rappresentati con minore accuratezza

2. Il pre-training: la prima e più costosa fase di apprendimento

2.1 Come avviene concretamente il pre-training

Il pre-training è la fase iniziale e computazionalmente più onerosa dell'addestramento di un Large Language Model, durante la quale il sistema viene esposto, in modo ripetuto e su scala enorme, al compito di prevedere quale sia la parola o la porzione di parola successiva più probabile all'interno di una sequenza di testo tratta dal dataset di

addestramento: un compito che, ripetuto su miliardi di esempi diversi, permette al modello di apprendere in modo del tutto implicito regolarità grammaticali, semantiche, stilistiche e persino un'ampia quantità di informazioni fattuali sul mondo.

Durante questa fase nessuna regola linguistica viene fornita esplicitamente al sistema: l'unico segnale di apprendimento a disposizione del modello è la differenza tra la parola effettivamente prevista e quella realmente presente nel testo originale, una differenza che viene utilizzata per correggere progressivamente, attraverso un procedimento matematico iterativo, i parametri interni del modello, fino a ridurre sensibilmente l'errore commesso su nuovi esempi mai osservati in precedenza.

Il pre-training si svolge tipicamente su un'unica, vastissima raccolta di testo generalista, senza alcuna distinzione tra compiti diversi: lo stesso identico processo di apprendimento permette al modello, al termine di questa fase, di mostrare competenze molto eterogenee, dalla scrittura alla traduzione, dal riassunto alla programmazione, tutte emerse dalla medesima, semplice logica di previsione della parola successiva applicata a una quantità di testo sufficientemente ampia e variegata.

Un aspetto spesso poco intuitivo di questo processo riguarda la sua natura progressiva: nelle fasi iniziali dell'addestramento il modello commette errori piuttosto grossolani, faticando persino a produrre frasi grammaticalmente corrette, mentre soltanto dopo aver osservato una quantità sufficientemente ampia di esempi comincia a mostrare le capacità linguistiche più articolate che caratterizzano un modello completamente addestrato, un miglioramento che non avviene in modo lineare, ma con salti di qualità osservabili soltanto oltre determinate soglie di dati e di calcolo impiegati.

2.2 Infrastrutture di calcolo, tempi e costi

Il pre-training di un Large Language Model di grandi dimensioni richiede infrastrutture di calcolo altamente specializzate, composte da migliaia di processori dedicati al calcolo parallelo, mantenuti in funzione ininterrottamente per settimane o mesi, un investimento economico che si colloca, per i modelli più avanzati, nell'ordine di decine o centinaia di milioni di euro, considerando sia il costo dell'energia elettrica necessaria sia quello dell'hardware specializzato coinvolto.

Questa scala di investimento spiega perché il pre-training di un modello di frontiera resti un'attività riservata a un numero relativamente ristretto

di organizzazioni al mondo, dotate delle risorse economiche e delle competenze tecniche necessarie, mentre la stragrande maggioranza delle attività, comprese le piccole imprese e i singoli professionisti, accede a questi modelli come utilizzatori finali di un servizio già addestrato, senza alcuna necessità, né convenienza pratica, di ripetere autonomamente un processo di questa portata.

Va peraltro segnalato che, accanto ai modelli di punta addestrati con investimenti di questa entità, esistono oggi anche modelli di dimensioni più contenute il cui pre-training, pur restando un'operazione tecnicamente complessa, richiede risorse sensibilmente inferiori: una tendenza che sta progressivamente ampliando, negli ultimi tempi, il numero di organizzazioni in grado di addestrare autonomamente modelli linguistici, seppure di dimensioni più circoscritte rispetto ai sistemi generalisti più noti.

2.3 Che cosa impara davvero un modello durante il pre-training

Al termine del pre-training, un Large Language Model, talvolta indicato come modello di base, possiede già una notevole capacità di comprendere e continuare un testo in modo linguisticamente coerente, ma si comporta ancora in un modo che può risultare poco utile per un utilizzo pratico e conversazionale: tende, ad esempio, a completare un

testo nel modo statisticamente più plausibile osservato nei dati, senza necessariamente rispondere in modo pertinente a una domanda diretta o seguire un'istruzione specifica fornita dall'utente.

Un modello di base, in altre parole, ha appreso in modo approfondito le regolarità del linguaggio e una vasta quantità di informazioni presenti nei testi osservati, ma non ha ancora appreso, in questa fase, a comportarsi come un assistente realmente utile, cortese e allineato alle aspettative di chi lo utilizza: un salto ulteriore che avviene soltanto nelle fasi successive di fine-tuning, descritte nella sezione seguente, che a partire da questa base trasformano il modello in uno strumento pienamente utilizzabile nella pratica quotidiana.

È proprio per questa ragione che, nel linguaggio comune, quando si parla di un assistente conversazionale basato su un Large Language Model ci si riferisce quasi sempre al risultato di questo intero percorso, pre-training seguito da fine-tuning, e non al solo modello di base: un elemento utile da tenere presente per comprendere come mai due fasi concettualmente distinte vengano spesso percepite, nell'uso quotidiano, come un unico processo indistinto.

In pratica

- Il pre-training addestra il modello a prevedere ripetutamente la parola successiva su enormi quantità di testo
- Richiede infrastrutture di calcolo specializzate e investimenti economici molto rilevanti
- Al termine di questa fase si ottiene un modello di base, non ancora pienamente utilizzabile come assistente
- La maggior parte delle attività utilizza modelli già addestrati da terzi, senza ripetere questo processo

3. Dal modello di base al modello allineato: il fine-tuning

3.1 Fine-tuning supervisionato: addestrare su esempi curati

La prima fase di perfezionamento che segue il pre-training è generalmente il fine-tuning supervisionato, durante il quale il modello di base viene ulteriormente addestrato su una raccolta più contenuta, ma accuratamente curata, di esempi che mostrano il comportamento desiderato: coppie di istruzioni e relative risposte appropriate, scritte o selezionate da persone incaricate a questo scopo, che insegnano al modello a rispondere in modo pertinente a una domanda diretta, a seguire un'istruzione specifica o a mantenere un tono comunicativo adeguato.

A differenza del pre-training, che si basa su una raccolta di testo generalista e non curata nel dettaglio, il fine-tuning supervisionato utilizza esempi selezionati proprio per il tipo di comportamento che si desidera ottenere, un processo che richiede risorse computazionali

molto inferiori rispetto al pre-training, poiché interviene su un modello che possiede già, dalla fase precedente, una solida comprensione di base del linguaggio.

Questa fase rappresenta il primo passaggio concreto attraverso cui un modello di base, capace soltanto di completare un testo in modo statisticamente plausibile, comincia a comportarsi in modo riconoscibile come un assistente: rispondendo a domande, seguendo istruzioni esplicite e adottando un registro comunicativo più simile a quello di una conversazione utile, piuttosto che a un semplice completamento automatico di un testo.

La qualità degli esempi utilizzati in questa fase incide in modo diretto sul risultato finale: raccolte curate con maggiore attenzione, che coprono una gamma ampia e ben bilanciata di tipologie di richieste, tendono a produrre modelli più versatili e affidabili rispetto a raccolte più ristrette o meno rappresentative, un motivo per cui le organizzazioni che sviluppano questi sistemi dedicano risorse crescenti proprio alla progettazione e alla revisione di questi esempi, oltre che alla loro effettiva raccolta.

3.2 L'apprendimento per rinforzo dal feedback umano (RLHF)

Una seconda tecnica di perfezionamento, oggi ampiamente diffusa, è l'apprendimento per rinforzo basato sul giudizio umano, comunemente indicato con l'acronimo inglese RLHF: un procedimento in cui persone incaricate a questo scopo confrontano diverse risposte generate dal modello a una medesima richiesta, indicando quale tra esse risulti preferibile in termini di utilità, chiarezza, correttezza e appropriatezza, valutazioni che vengono poi utilizzate per orientare ulteriormente il comportamento del modello.

Concretamente, queste valutazioni comparative vengono utilizzate per addestrare un secondo modello, spesso indicato come modello di ricompensa, incaricato di stimare quanto una risposta risulti preferibile secondo i criteri osservati nei giudizi umani raccolti; il modello linguistico principale viene poi ulteriormente perfezionato in modo da massimizzare, nelle proprie risposte, il punteggio assegnato da questo modello di ricompensa, un meccanismo indiretto ma efficace per orientare il comportamento del sistema verso risposte considerate migliori dalle persone.

Il contributo di questa fase alla qualità percepita di un assistente conversazionale è notevole, e spiega in larga parte perché due modelli

con caratteristiche tecniche di base per certi versi simili possano comportarsi, nell'uso quotidiano, in modo percepibilmente diverso: un modello sottoposto a un processo di RLHF particolarmente accurato tende infatti a risultare più utile, più coerente con le istruzioni ricevute e meno incline a produrre risposte inappropriate o poco pertinenti rispetto a un modello che abbia ricevuto un perfezionamento meno approfondito in questa fase.

3.3 Fine-tuning per compiti specifici: instruction tuning e personalizzazione di dominio

Oltre al perfezionamento generale volto a rendere un modello un assistente utile e sicuro nell'uso quotidiano, è possibile sottoporre un Large Language Model già addestrato a un ulteriore fine-tuning mirato su un compito o un ambito specifico, fornendo al modello esempi relativi a quel particolare dominio, come la terminologia tecnica di un settore, lo stile comunicativo caratteristico di un'organizzazione, o un formato di risposta particolarmente strutturato richiesto da un'applicazione specifica.

Questa tecnica, spesso definita fine-tuning di dominio o personalizzazione, permette di unire la flessibilità e la vasta conoscenza generale acquisita da un modello durante il pre-training a un livello di

accuratezza più elevato su un compito circoscritto, senza dover addestrare un sistema interamente nuovo da zero: un'opzione oggi accessibile, con costi e complessità tecnica sensibilmente inferiori rispetto al pre-training originario, anche a organizzazioni di dimensioni contenute che dispongano di dati sufficientemente rappresentativi del proprio ambito di attività.

Va peraltro segnalato che, per molti utilizzi pratici quotidiani, un fine-tuning di dominio vero e proprio non è affatto necessario: come si vedrà nella sezione successiva, è spesso possibile ottenere un livello di personalizzazione più che sufficiente semplicemente fornendo al modello, all'interno della conversazione stessa, istruzioni esplicite, esempi o documenti di riferimento relativi alla propria attività, senza alcuna necessità di intervenire sui parametri interni del modello attraverso un ulteriore addestramento.

Un ulteriore vantaggio del fine-tuning di dominio, quando effettivamente praticabile, riguarda la possibilità di ridurre la lunghezza delle istruzioni da fornire a ogni singola richiesta: un modello già specializzato su un determinato ambito tende infatti a comportarsi correttamente anche con richieste più sintetiche, avendo incorporato

stabilmente, nei propri parametri, le convenzioni e la terminologia specifiche di quel dominio, a differenza di un modello generalista a cui tali indicazioni vanno fornite ogni volta all'interno della conversazione.

In pratica

- Il fine-tuning supervisionato insegna al modello, tramite esempi curati, a rispondere in modo pertinente
- L'RLHF perfeziona ulteriormente il modello sulla base di giudizi comparativi espressi da persone
- Un fine-tuning di dominio permette di specializzare un modello su un ambito o un compito specifico
- Per molti usi quotidiani, istruzioni e documenti forniti in conversazione possono bastare senza un fine-tuning dedicato

4. Dataset, pre-training e fine-tuning: effetti pratici sulla qualità del modello

4.1 Perché due modelli "della stessa famiglia" possono comportarsi diversamente

Chi utilizza regolarmente strumenti di intelligenza artificiale generativa nota spesso come versioni diverse di uno stesso modello, o modelli sviluppati da organizzazioni differenti ma di dimensioni per certi versi comparabili, possano fornire risposte sensibilmente diverse a una medesima richiesta: una variabilità che si spiega proprio con le differenze, spesso non visibili dall'esterno, nella composizione del dataset di addestramento, nei dettagli tecnici del pre-training e,

soprattutto, nell'entità e nella qualità del successivo lavoro di fine-tuning e allineamento.

Anche a parità di dimensione del modello e di architettura di base, un lavoro di perfezionamento più accurato, condotto con maggiore attenzione e su un numero più ampio di esempi valutati da persone, tende a produrre un assistente percepito come più utile, più coerente e più affidabile nell'uso quotidiano, un fattore che rende il numero di parametri, da solo, un indicatore piuttosto incompleto della qualità effettiva di un modello per un utilizzo pratico.

Questa osservazione ha una ricaduta pratica diretta per chi deve scegliere tra diversi strumenti disponibili: confrontare le prestazioni concrete su compiti rilevanti per la propria attività risulta generalmente più utile che basare la scelta unicamente su caratteristiche tecniche dichiarate, come il numero di parametri o la quantità di dati di addestramento utilizzati, informazioni che, peraltro, non tutte le organizzazioni rendono pubblicamente disponibili con lo stesso livello di dettaglio.

4.2 Versioni, aggiornamenti e cicli di rilascio dei modelli

I Large Language Model messi a disposizione del pubblico vengono periodicamente aggiornati con nuove versioni, il cui addestramento incorpora dati più recenti, correzioni dei limiti emersi nell'uso della versione precedente, e un lavoro di fine-tuning ulteriormente affinato sulla base dell'esperienza accumulata: un ciclo di rilascio che, negli ultimi anni, si è mantenuto piuttosto rapido, con nuove versioni principali che si susseguono nell'arco di alcuni mesi.

Ogni nuova versione comporta, in linea di principio, un nuovo ciclo di pre-training, o quantomeno un aggiornamento sostanziale dello stesso, seguito da una nuova fase di fine-tuning: un processo che spiega perché la data di riferimento delle conoscenze fattuali di un modello, il cosiddetto cutoff, avanzi progressivamente nel tempo a ogni nuova versione rilasciata, pur restando sempre, per definizione, antecedente al momento in cui il modello viene reso disponibile.

Per chi utilizza questi strumenti in un contesto professionale, tenere conto dell'esistenza di versioni diverse dello stesso modello, e delle differenze anche significative di comportamento che ne possono derivare, aiuta a interpretare correttamente eventuali discrepanze osservate rispetto a esperienze precedenti, ed evita di attribuire a un

problema dello strumento ciò che, più semplicemente, riflette l'evoluzione naturale di un sistema periodicamente riaddestrato e perfezionato.

Questo ritmo di aggiornamento comporta anche una conseguenza pratica da tenere presente: competenze e accorgimenti acquisiti nell'uso di una determinata versione di un modello restano generalmente validi anche con le versioni successive, poiché i principi di funzionamento di fondo, descritti in questo approfondimento, non mutano da una versione all'altra, mentre possono cambiare, anche sensibilmente, il livello di accuratezza raggiunto e la naturalezza delle risposte ottenute.

4.3 Che cosa cambia, in pratica, per chi utilizza questi strumenti

Conoscere la distinzione tra dataset, pre-training e fine-tuning permette di formulare aspettative più realistiche nei confronti di uno strumento di intelligenza artificiale generativa: un modello non ha alcuna conoscenza di eventi successivi alla data di cutoff del proprio addestramento, per cui su informazioni molto recenti resta preferibile affidarsi a fonti aggiornate o a strumenti che integrino esplicitamente una funzione di ricerca esterna.

Allo stesso modo, sapere che il comportamento più propriamente conversazionale e allineato di un assistente deriva dal lavoro di fine-tuning, e non dal solo pre-training, aiuta a comprendere perché fornire al modello un contesto chiaro, istruzioni esplicite ed eventuali esempi del risultato desiderato tenda a migliorare sensibilmente la qualità delle risposte ottenute, un accorgimento che sfrutta proprio la capacità, appresa in questa fase, di seguire indicazioni specifiche fornite dall'utente.

Infine, la consapevolezza che il comportamento di un modello riflette, in ultima analisi, i dati e le scelte di perfezionamento operate da chi lo ha sviluppato invita a un atteggiamento equilibrato nei confronti di questi strumenti: né un rifiuto aprioristico, né una fiducia incondizionata, ma una valutazione caso per caso, tanto più attenta quanto più rilevanti sono le conseguenze pratiche delle decisioni che si intende basare sulle risposte ottenute.

In pratica

- Le differenze di comportamento tra modelli dipendono da dataset, pre-training e, soprattutto, fine-tuning
- Il numero di parametri, da solo, non è un indicatore sufficiente della qualità di un modello
- Ogni nuova versione di un modello comporta un nuovo ciclo di addestramento e una data di cutoff più recente

- Conoscere questi passaggi aiuta a formulare aspettative realistiche e a scrivere istruzioni più efficaci

5. Considerazioni pratiche per un utilizzo consapevole

5.1 Come riconoscere se un modello è aggiornato o "specializzato"

Molti strumenti basati su Large Language Model indicano, all'interno della propria documentazione ufficiale o direttamente nell'interfaccia utilizzata, la data approssimativa di cutoff delle conoscenze del modello, un'informazione utile da verificare prima di affidarsi al sistema per questioni che richiedono informazioni aggiornate, e che permette di distinguere tra un modello recentemente addestrato e uno la cui ultima versione risale a un periodo più lontano nel tempo.

Allo stesso modo, alcuni strumenti dichiarano esplicitamente di essere stati sottoposti a un fine-tuning specifico per un determinato ambito professionale, come quello legale, medico o finanziario, un'indicazione che, se presente, segnala un livello di accuratezza potenzialmente più elevato su quei temi specifici rispetto a un modello generalista, pur senza sostituire, in ambiti particolarmente delicati, la necessaria verifica da parte di una persona competente nella materia.

In assenza di indicazioni esplicite, un modo semplice e pratico per farsi un'idea del livello di aggiornamento di un modello consiste nel porre direttamente una domanda relativa a un evento di cui si conosce la data, osservando se e come il sistema segnala l'eventuale mancanza di informazioni più recenti, un piccolo accorgimento che aiuta a calibrare correttamente il livello di fiducia da riporre nelle risposte ottenute su temi legati all'attualità.

5.2 Personalizzare un modello per la propria attività: opzioni disponibili

Per una piccola attività che desideri ottenere risposte più coerenti con il proprio settore, il proprio tono di voce o la propria terminologia specifica, un vero e proprio fine-tuning di dominio, con i costi e le competenze tecniche che comporta, risulta raramente la soluzione più praticabile o conveniente, essendo un'opzione pensata soprattutto per organizzazioni con esigenze di scala e risorse dedicate.

Un'alternativa molto più accessibile consiste nel fornire al modello, all'interno della conversazione stessa, un contesto sufficientemente ricco: istruzioni esplicite su tono, stile e vincoli desiderati, esempi concreti di testi già prodotti in passato da imitare, o documenti di riferimento specifici della propria attività da consultare per rispondere

a una particolare richiesta, un approccio che sfrutta pienamente le capacità di comprensione del contesto acquisite dal modello durante il proprio addestramento, senza alcun intervento sui suoi parametri interni.

Alcuni strumenti offrono inoltre funzionalità dedicate proprio a questo scopo, permettendo di salvare istruzioni permanenti valide per ogni nuova conversazione, oppure di collegare il modello a una raccolta di documenti propri da consultare prioritariamente rispetto alla sola conoscenza generale appresa durante l'addestramento, un'opzione che avvicina, per molti utilizzi pratici quotidiani, i benefici di una personalizzazione di dominio senza richiederne i costi né la complessità tecnica.

Un ulteriore accorgimento pratico consiste nel costruire, nel tempo, una piccola raccolta personale di esempi particolarmente riusciti, come email, descrizioni di prodotto o documenti che si ritengono ben scritti e rappresentativi del proprio stile, da fornire al modello come riferimento nelle richieste successive: un metodo semplice e alla portata di chiunque per ottenere risultati progressivamente più coerenti

con le proprie abitudini comunicative, senza alcuna competenza tecnica aggiuntiva rispetto al normale utilizzo dello strumento.

5.3 Domande utili da porsi prima di scegliere uno strumento basato su LLM

Alla luce di quanto descritto, alcune domande semplici possono orientare la scelta tra i diversi strumenti di intelligenza artificiale generativa oggi disponibili: quanto risulta recente la data di cutoff dichiarata delle conoscenze del modello, rispetto alle esigenze specifiche della propria attività; lo strumento integra, se necessario, una funzione di ricerca esterna in grado di recuperare informazioni più aggiornate rispetto a quelle apprese durante l'addestramento.

Ulteriori aspetti utili da considerare riguardano la possibilità di fornire al modello istruzioni permanenti o documenti di riferimento propri, così da ottenere risposte più coerenti con le proprie esigenze senza ricorrere a un fine-tuning dedicato, e la disponibilità di indicazioni chiare, da parte di chi sviluppa lo strumento, sul tipo di dati utilizzati per l'addestramento e sulle eventuali limitazioni note del sistema.

Nessuna di queste domande sostituisce, da sola, una valutazione pratica diretta condotta sui compiti realmente rilevanti per la propria attività:

la comprensione dei principi di funzionamento descritti in questo approfondimento resta comunque un presupposto utile per interpretare correttamente i risultati di tale valutazione, e per orientarsi con maggiore consapevolezza tra gli strumenti di intelligenza artificiale generativa oggi disponibili.

In pratica

- Verificare, quando disponibile, la data di cutoff delle conoscenze di un modello prima di affidarvisi su temi recenti
- Preferire, per un utilizzo quotidiano, la personalizzazione tramite istruzioni e documenti al fine-tuning dedicato
- Verificare se lo strumento integra una funzione di ricerca esterna per informazioni aggiornate
- Valutare sempre i risultati sui compiti concreti della propria attività, oltre alle sole caratteristiche dichiarate

In sintesi

L'addestramento di un Large Language Model si articola in fasi distinte e complementari: la raccolta e la preparazione di un dataset di dimensioni enormi, il pre-training, in cui il modello apprende le regolarità generali del linguaggio, e una o più fasi successive di fine-tuning, comprensive di tecniche come l'apprendimento per rinforzo dal feedback umano, che trasformano un modello di base in un assistente realmente utile, coerente e allineato alle aspettative di chi lo utilizza.

Conoscere questo percorso, dai dati di partenza fino al modello che si utilizza quotidianamente, permette di comprendere meglio tanto le straordinarie capacità quanto i limiti strutturali di questi strumenti, e fornisce le basi per un utilizzo più consapevole, capace di sfruttarne appieno il potenziale senza affidarvisi in modo acritico, un presupposto che resta valido qualunque sia lo strumento specifico di intelligenza artificiale generativa che si sceglie di utilizzare nella propria attività.